

La randomizzazione nella valutazione d'impatto

Benedetta Valpreda

Settembre 2023

1 Introduzione teorica

Misurare l'impatto di un programma significa inferire il suo effetto causale su un certo outcome escludendo l'influenza da parte di un qualsiasi altro fattore confondente.

Idealmente, per misurare tale impatto si vorrebbe confrontare l'outcome di un individuo in presenza del trattamento e l'outcome dello stesso individuo in assenza del trattamento ma ciò è impossibile (il secondo termine, chiamato controfattuale, è inosservabile per i trattati e va stimato).

Per stimare il controfattuale serve trovare il *gruppo di controllo opportuno tra i non trattati*, cioè il gruppo più simile possibile al gruppo di trattati in assenza del programma.

Due strategie per stimare il controfattuale immediate ma inopportune sono:

- confrontare i beneficiari prima e dopo, ma questo non va bene perché ci sono fattori confondenti
- tra gli idonei confrontare i partecipanti (o meglio chi ha scelto di partecipare) e i non partecipanti, ma questo non va bene per fattori inosservabili (es: motivazione)

Più specificatamente, la pratica (2) è inopportuna perché la differenza negli outcome tra i partecipanti e i non-partecipanti non è data soltanto dall'effetto che il programma ha sull'outcome (impatto ricercato) ma anche dalla differenza negli outcome che distingueva i due gruppi già in partenza (selection bias).

Il metodo più robusto in assoluto per stimare l'impatto di un programma è la randomizzazione, che consiste nell'assegnare casualmente gli idonei a un gruppo di trattati (idonei beneficiari) o a un gruppo di controllo (idonei non beneficiari). La randomizzazione garantisce che il gruppo assegnato al trattamento e quello assegnato al controllo siano in media uguali in tutte le caratteristiche (anche quelle inosservabili) in assenza del programma.

Di conseguenza, la randomizzazione elimina il selection bias tra i due gruppi: in assenza del programma gli outcome dei due gruppi sono in media uguali. Quindi se dopo il programma si osservano eventuali differenze negli outcome

queste possono essere attribuite al programma stesso, perchè era l'unico elemento che distingueva i due gruppi.

Questa introduzione teorica è stata liberamente ispirata a [Gertler et al., 2016].

2 Caso studio

L'obiettivo di questo progetto è svolgere delle simulazioni per confrontare due scenari diversi e mostrare che in quello con randomizzazione si stima l'impatto del programma in modo robusto.

Immaginiamo un caso di studio ipotetico in cui un team di ricercatori sia stato incaricato di valutare l'impatto che un certo progetto di up-skilling ha sul reddito dei giovani.

Consideriamo due scenari diversi:

1. **Auto-selezione:** i ragazzi idonei scelgono liberamente se partecipare o meno al programma di up-skilling. In questo scenario, i giovani con più motivazione hanno più probabilità di partecipare al programma.
2. **Randomizzazione:** i ragazzi idonei sono assegnati casualmente o meno al programma. In questo scenario, la partecipazione è casuale e quindi non dipende nè dalla motivazione nè da un qualsiasi altro fattore

Per i due scenari sopracitati generiamo ripetutamente diversi dataset e da ciascuno di questi otteniamo una stima dell'effetto del programma sul reddito. In seguito, calcoliamo l'effetto medio trovato tra tutte le simulazioni e confrontiamo i risultati finali tra i due scenari.

3 Generazione dei dati

Per il caso studio considerato, l'outcome di interesse è il reddito. Le variabili esplicative considerate sono:

- genere: dummy che vale 1 per le femmine e 0 per i maschi
- nazionalità: dummy che vale 1 per gli stranieri e 0 per i connazionali.
- età: variabile numerica tra 18 e 25
- anni di istruzione: variabile numerica tra 13 e 18
- motivazione: variabile inosservabile distribuita come una normale standard
- trattamento: dummy che vale 1 per i trattati (idonei beneficiari) e 0 per i controlli. Nello Scenario 1 viene generata in base alla motivazione mentre nello Scenario 2 viene generata in modo casuale

Possiamo immaginare che il reddito dei giovani dipenda da queste caratteristiche individuali (osservabili e non) e da una componente casuale inosservabile e inspiegabile (un termine di errore casuale che può rappresentare, per esempio, la "fortuna"). Perciò l'outcome di interesse (il reddito) viene generato in questo progetto attraverso il seguente modello:

$$\begin{aligned} \text{reddito} = & 1500 + 100\text{trattati} - 200\text{femmina} - 300\text{straniero} \\ & + 20\text{eta} + 10\text{anni_istruzione} + 50\text{motivazione} + \epsilon \end{aligned}$$

In questo modello, l'effetto vero del trattamento sul reddito è pari a 100. Nella pratica, questo effetto sarebbe sconosciuto e quindi da stimare.

4 Metodi di stima

Per i due scenari considerati, l'effetto del programma sul reddito viene stimato, per ogni dataset generato, in 3 modi diversi:

1. **Differenza tra outcome medi:** nel dataset corrente, si calcola il reddito medio dei trattati, il reddito medio dei controlli e la differenza tra questi due termini.
Dalla teoria, ci aspettiamo che nello Scenario 1 questa differenza rappresenti la somma tra l'effetto del trattamento ricercato e il selection bias, mentre nello Scenario 2 coincida con l'impatto desiderato.
2. **Coefficiente stimato in una regressione semplice:** nel dataset corrente, si stima una regressione del reddito sulla dummy di trattamento.
In sostanza, questo metodo è analogo al precedente, infatti il risultato ottenuto coincide con quello calcolato con il primo modo.
3. **Coefficiente stimato in una regressione multipla:** nel dataset corrente, si stima una regressione del reddito su tutte le esplicative osservabili (quindi la motivazione viene omessa).
Poiché nello Scenario 1 il trattamento è correlato con la motivazione e la motivazione è una esplicativa del reddito (compare nell'equazione del DGP), dall'omissione di questa variabile ci aspettiamo che l'effetto del trattamento sul reddito sia distorto. Nello Scenario 2 invece, la motivazione viene esclusa ma non è correlata con il trattamento, pertanto non si presenta il problema della distorsione da variabile omessa e ci aspettiamo che l'effetto del trattamento sia stimato in modo robusto.

Ottenute per ogni dataset generato le stime dell'effetto in queste tre maniere, procediamo a calcolare la media tra tutti i valori ottenuti e a ricavare i risultati finali per entrambi gli scenari considerati.

5 Risultati

In questa sezione riportiamo i risultati finali ottenuti per i due scenari svolgendo 2000 simulazioni.

	stima media
Differenza	180.12576
Regressione semplice	180.12576
Regressione Multipla	179.76609

Table 1: Risultati Scenario 1 (Auto-selezione)

La Tabella 1 si riferisce allo scenario di auto-selezione, in cui i giovani idonei scelgono se partecipare o meno al programma di up-skilling in base alla loro motivazione. Questa tabella presenta i risultati ricavati mediando le stime ottenute su ognuno dei 2000 dataset generati nei tre modi indicati sopra. Notiamo che la differenza tra gli outcome (modo 1) non coincide con il vero effetto (pari a 100) bensì risulta essere una sovra-stima. In questo caso infatti i due gruppi erano diversi già in partenza (i trattati sono mediamente più motivati e i più motivati guadagnano mediamente di più) e pertanto la differenza tra gli outcome ingloba anche un termine di selection bias. Notiamo inoltre che anche l'effetto stimato nella regressione multipla (modo 3) risulta essere sovra-stimato. Come già accenato infatti in questo caso omettere la motivazione porta a una distorsione sull'effetto stimato del trattamento.

	stima media
Differenza	100.15159
Regressione semplice	100.15159
Regressione Multipla	100.05834

Table 2: Risultati Scenario 2 (Randomizzazione)

La Tabella 2 si riferisce invece allo scenario di randomizzazione in cui la partecipazione al programma da parte dei giovani idonei è totalmente casuale e mostra i risultati ottenuti in questo caso.

Notiamo che, per tutti e tre i metodi di stima, i risultati sono molto vicini al vero effetto del trattamento sul reddito.

Come già spiegato infatti in presenza di randomizzazione i due gruppi sono in media identici in tutto in assenza del trattamento e quindi non esiste selection bias. Di conseguenza, la differenza tra gli outcome (modo 1) coincide con l'impatto ricercato.

Inoltre, poichè il trattamento è casuale (e quindi scorrelato da qualsiasi altro fattore), escludere la motivazione non porta a problemi di distorsione nella stima dell'effetto desiderato nel metodo con regressione multipla (modo 3).

6 Conclusione

In conclusione, questo progetto ha mostrato che, in ambito di valutazione delle politiche, assegnare casualmente gli idonei ai gruppi di trattati e di controlli permette di eliminare il selection bias tra i due gruppi e quindi di stimare l'impatto del programma senza distorsioni.

Appendice

In questa Appendice si approfondisce la distorsione nello Scenario 1.

Per semplicità concentriamoci solo sul reddito, sulla variabile di trattamento e sulla motivazione.

Il vero modello è:

$$reddito = \beta_0 + \beta_1 trattamento + \beta_2 motivazione + u \quad (1)$$

Con u termine di errore casuale, ortogonale a tutto per ipotesi.

Poichè la motivazione è inosservabile, la omettiamo e stimiamo un modello con equazione:

$$reddito = \tilde{\beta}_0 + \tilde{\beta}_1 trattamento + w \quad (2)$$

Con w termine di errore casuale, ortogonale a tutto per ipotesi.

Calcoliamo la $Cov(reddito, trattamento)$:

$$Cov(reddito, trattamento) = \quad (3)$$

$$Cov(\tilde{\beta}_0 + \tilde{\beta}_1 trattamento + w, trattamento) = \quad (4)$$

$$\tilde{\beta}_1 Var(trattamento) \quad (5)$$

Da cui segue:

$$\tilde{\beta}_1 = \frac{Cov(reddito, trattamento)}{Var(trattamento)} \quad (6)$$

Se ora sostituiamo in 6 la definizione del reddito in 1 otteniamo:

$$\tilde{\beta}_1 = \frac{Cov(reddito, trattamento)}{Var(trattamento)} = \quad (7)$$

$$\frac{Cov(\beta_0 + \beta_1 trattamento + \beta_2 motivazione + u, trattamento)}{Var(trattamento)} = \quad (8)$$

$$\beta_1 \frac{Var(trattamento)}{Var(trattamento)} + \beta_2 \frac{Cov(motivazione, trattamento)}{Var(trattamento)} = \quad (9)$$

$$\beta_1 + \beta_2 \delta \quad (10)$$

dove δ è il coefficiente nella regressione della motivazione sul trattamento.

Di conseguenza, $\tilde{\beta}_1$ nel modello con la motivazione omessa (che nell'esempio vale circa 179) è dato dal vero effetto β_1 del trattamento (nell'esempio 100) e da un

secondo termine che dipende dal vero effetto β_2 della motivazione (nell'esempio 50) e dal legame δ tra la motivazione e il trattamento.

Tornando al caso studio, possiamo stimare la regressione della motivazione sul reddito e stimare δ , trovando, in media, $\hat{\delta} = 1.595$.

Calcoliamo $\tilde{\beta}_1 = 100 + 50 * 1.595 = 179.7686$, che è molto simile all'effetto sovrastimato trovato quando si omette la motivazione che valeva, in media, 179.76609, come mostrato nella Tabella 1.

References

P. Gertler, S. Martinez, P. Premand, L. Rawlings, and C. Vermeersch. *Impact Evaluation in Practice*. 2016.